

DeepProf

M1–M3 工程实验报告

v0.6.2 · 中文版 · 2026-09-24

本报告梳理 A/B/C 教学流程、BKT

工程验证、离线回放与真实模型截断试跑。数据仅用于工程验收与失败分析，没有真实学生参与或学习效果结论。

核心结果：M1 完成 76/80 格；M2 历史批次 82 项定向与 309 项回归通过；发布核验 Python 318 项通过；M3 离线 400 格完成但 BKT 预测不佳；真实模型试跑仅 3 次完整生成，26 次截断。

研究问题

评估本地教学策略、学习历史/BKT、证据检索与回放的工程路径是否可运行、可隔离并能保留失败证据。

构造案例和离线测试不能替代教师评审或真实学生研究；报告只支持工程验证与失败定位。

系统与实验方法

系统路径：npm CLI → 本机 Gateway/API → 策略图与技能 → 课程/证据检索 → Attempt/BKT 存储与事件回放。A 为基线策略，B 为规则教学图，C 在 B 的教学流程中启用 BKT 学情读取。

BKT 仅用可靠、明确归属、未提示的已评分 Attempt；重复或待评记录跳过。参数 $P(L)=0.20$ 、 $P(T)=0.10$ 、 $P(G)=0.20$ 、 $P(S)=0.10$ 是开发初值，尚未拟合。

每个批次保留 run_id、时间、样本类型、配置、分母、数据关联、图号和可用源指纹。历史运行不与本轮打包验证混合。

M1 · A/B 工程运行

运行 run_20260923T235151Z_ed03930c 覆盖 40 个构造案例 × A/B 共 80 格，76 格完成、4 格失败；A 组 40/40，B 组 36/40。4 格均为 empty_model_response。审计运行记录完整，自动行为核验 76/80，通过状态为 needs_attention。

失败案例 DSDEV-001、DSDEV-016、DSDEV-018、DSDEV-020 均属于 B 组；Provider 以长度上限终止且未返回正文。只保留构造案例号与结构化错误原因。

原试验调用 123 次 Provider。之后修复后的复测在 HTTP 401 前置检查处终止，未发送案例。M1 审计没有导出可独立核验的指纹摘要，证据清单记录该限制。

M2 · 工程验收

历史冻结 M2 批次的定向验收 82 项、Python 全量回归 309 项和 CLI 测试 5 项均通过，TypeScript 类型检查通过。82 项属于 309 项的子集，不得相加；更早的 77/300/3 也作为历史记录保留。

测试覆盖 BKT 更新、Attempt 幂等/资格、SQLite 并发与事务、组间隔离、课程题库、文档转换和契约。教师审核和 BKT 参数校准尚未完成。

v0.6.2 · 独立发布验证

本次发布验证与历史批次分开记录：Python 回归 318/318，M2 定向 82 项包含在这 318 项内；CLI 7/7、TypeScript 构建/类型检查通过。新增 Fake Provider 离线验证完成主矩阵 120、回放 120、消融 160 格，未调用付费模型。

最终 CLI tar 在本机以 npx 执行版本、帮助、安装复用与 Gateway doctor 检查通过。跨平台 GitHub CI 和公开 Release URL 端到端安装尚待远程发布 workflow 执行；不计为已通过。

M3 · Fake Provider 离线试跑

40 个构造案例产生主矩阵 120/120、回放 120/120、RAG 消融 160/160，共 400 格。动作族匹配 196/280；回放一致 120/120；决策字段完整 520/520；引用字段可定位 189/189。

BKT 预测 $n=120$ ：AUC 0.2964，Brier 0.3656，log loss 0.9361，ECE 0.5299。AUC 低于 0.5 参照且校准误差偏高，是应保留的不利结果。

无检索且证据约束启用时 40/40 格阻断生成；关闭约束时 26/40 格触发生成。此消融只确认路径开关生效。

M3 · 真实模型试跑

12 案例 × A/B/C 共 36 格，29 次 Provider 请求，零重试，另 7 格未生成。应用终态完成 26/36、失败 10/36；评测完整生成 3/29、截断失败 26/29、无生成不适用 7/36。

Provider finish_reason=length 按失败处理，即使应用终态为 completed。一次服务端用量报告 513 个 completion tokens，高于配置 512；保留该异常且未重试。


局限与下一步

完成教师盲评、引用语义支持与答案泄露标注，校准 BKT 参数，修复生成截断并重新冻结协议后复测，再讨论真实学生试点设计。

所有结果均来自软件用例、自动测试或单次小规模真实模型试跑。没有教师评分一致性数据，也没有真实学生学习效果证据。

F01 · 首批题库

样本量与单位：N=30 道题；单位为题目




数据来源：figure-data.csv 与 experiment-snapshot.json

解释边界：描述题目及评分状态，不说明学习效果。

F02 · M1 A/B 运行格

样本量与单位：40 个构造案例 × A/B；计划 N=80 格




数据来源：figure-data.csv 与 acceptance-audit.json

解释边界：4 个 B 组失败保留；无真人参与者。

F03 · 教材页码核对

样本量与单位: N=347 个 PDF 页; 人工核验 7 页




数据来源: figure-data.csv 与 experiment-snapshot.json

解释边界: 340 页仍待人工核验。

F04 · 构造案例类型

样本量与单位：N=40 个构造案例，8 类各 5 例




数据来源：figure-data.csv 与 dev case version

解释边界：开发分支测试样例，不是真人观察。

F05 · A/B 运行性能

样本量与单位：76/80 格；脚本化回合延迟/Token

真实 Provider A/B 运行概览



数据来源：turn-performance.csv 与 experiment-snapshot.json


解释边界：仅为工程运行测量；历史自动 PDF 扫描保留 needs_review。

F06 · M2 自动验收

样本量与单位：309 Python、82 M2 定向、5 CLI 测试项

M2 自动化验收结果

柱长为通过的固定测试项数；M2 定向集包含在 Python 全量回归中，两者不可相加，也不代表学生学习效果。



数据来源：m2-validation.csv 与 M2-offline-acceptance.md


解释边界：定向 82 项包含在 Python 回归中，不相加。

F07 · 真实试跑前本地预检

样本量与单位：12 案例 × A/B/C，共 36 个计划格

M3 真实模型试点：检索预检完成，推理未启动

12 个构造开发案例 × A/B/C；每行计划分母为 12，真实推理合计 0/36 格



蓝色表示有可定位检索结果，橙色表示证据不足，灰色表示等待授权。
尚未调用外部模型，费用未产生；教师审核待完成，学生学习效果未测量。

数据来源：m3-live-pilot-preflight.csv 与历史 JSON


解释边界：历史预检为零 Provider 调用；不代表实际试跑。

F08 · M3 真实模型试跑

样本量与单位：36 格、29 次请求；单位为格和请求

M3 live pilot: Provider outcomes by group

36 constructed cells | 29 Provider requests | 512-token cap | 0 retries



A request ending with finish_reason=length is counted as truncated, even when the app terminal state was OK.

There were 26 length endings, 3 stop endings and 7 cells with no generation request.

Sixteen B/C cells ended at length while the app reported a completed turn; this is not generation success.

One usage report showed 513 completion tokens against the configured 512-token limit. Constructed cases only; not teacher-rated and not evidence of student learning.

数据来源：m3-live-pilot-live-cells.csv 与聚合 JSON


解释边界：3 次完整、26 次截断、7 格未触发生成。

F09 · M3 离线矩阵与预测

样本量与单位: 120 主矩阵 + 120 回放 + 160 消融; BKT n=120

M3 offline evaluation: complete execution, poor BKT prediction

run_id m3-offline-20260924-final6 | Fake Provider | constructed developer cases | no human participants



Engineering path checks only. Action match is not teacher rating; locatable references do not prove semantic support.
BKT uses unfit development parameters. Ablation records path behavior, not answer correctness.

数据来源: F09-m3-offline-summary.csv 与 M3-offline-summary-redacted.json

解释边界: Fake Provider 和合成 Attempt; BKT 未校准。