

BKT 与 RAG 改进实验报告

批次: bkt-rag-improvement-20261001 更新日期: 2026-10-05 用途: 研究评测; 不改变课程默认参数。

本轮结论

BKT 的主要优化证据来自 ASSISTments 开发集按学生分组的嵌套 OOF。题目相关猜测/失误参数是当前表现最好的探索性候选; 它提高 AUC、降低 Log loss 与 Brier, 但 ECE 点估计恶化且区间跨零, 尚不应冻结为课程模型。构造集的退化现象得到分层解释, 但该集没有足够序列长度或概念覆盖变化来估计边界。

全文 OCR 为347/347页; 新批次正式矩阵已完成, 有效 / 观察 / 计划格为480/480/480。AI标注已保存检索13710条、引用1595条、可答性120题。真实人员复核待实际评审提交。

NoMIRACL中文固定候选全量评测已完成: 37,599配对; 测试门限FAR=4.51%、FRR=70.11%、AUC=0.8007。这是候选排序与证据接受判断, 人员复核保持待提交。

数据与边界

用途	数据	状态与解释
BKT 退化诊断	40 条构造序列、120 次作答、21 个知识点	全部长度为 3, 只有 FFF/TFT/TTT 三类历史; 留概念折所有测试概念训练覆盖均为 0。仅作故障诊断。
BKT 新开发比较	ASSISTments 2009–2010; 开发集 3,202 名学生、184,631 次作答	按学生分组的外层 5 折×内层 4 折; 这是本轮可用的开发证据。
BKT 历史回归	ASSISTments 锁定测试集 801 名学生、51,429 次作答	测试集已被历史实验查看; 本轮只作回归检查, 不称为独立验证。
计划的新课程 BKT 测试	Algebra I 2005–06/2006–07 完整 KDD_master.txt	官方数据页要求注册下载; 完整文件未取得, 不使用截断样例替代。
课程 RAG	冻结教材索引、旧 40 题、新80题 (可答性按全文复核)	AI可答性按全文独立复核, 人员复核待实际提交; 近重复家族不跨开发/封存集。
公开 RAG 验证	NoMIRACL 中文固定候选; MIRACL 中文全库	NoMIRACL 全部3,770题固定候选评测已完成; MIRACL 全库未建490万级语料向量索引。

BKT 分层退化诊断

构造集复核采用 correct=1、当前作答前预测、并列分数平均秩 AUC, 以及五折知识点留出。原始 BKT AUC=0.2964; 留概念拟合 AUC=0.2931; 折内训练常数汇总 AUC=0.4177。该折内常数跨折汇总后 AUC 不必等于 0.5。构造集按知识点聚类的探索性区间跨零。不能从此推出长度 1/4+ 或有训练覆盖概念的性能。

公共锁定测试总体历史参考为 AUC 0.7143、Log loss 0.5760、ECE 0.00735。以下分层用于定位已见测试集中的回归边界; 不是选型证据。所有覆盖计数由对应训练折产生; 在当前学生分组折中, 测试覆盖为 0 的层为空。

分层轴	分层	测试作答 (正/负)	收缩 BKT AUC	ΔAUC vs 全局常数	配对 95% CI	Log loss	判读
完整序列长度	1-3	4972 (3907/1065)	0.768	0.268	[0.252, 0.285]	0.490	区间高于 0
完整序列长度	11-20	12766 (8036/4730)	0.710	0.210	[0.192, 0.227]	0.594	区间高于 0
完整序列长度	21+	17670 (10641/7029)	0.687	0.187	[0.167, 0.206]	0.619	区间高于 0
完整序列长度	4-10	16021 (11017/5004)	0.742	0.242	[0.226, 0.257]	0.541	区间高于 0
预测时已有作答	0-2	16729 (10740/5989)	0.697	0.197	[0.188, 0.207]	0.596	区间高于 0
预测时已有作答	10+	16716 (10704/6012)	0.708	0.208	[0.187, 0.227]	0.587	区间高于 0

分层轴	分层	测试作答 (正/负)	收缩 BKT AUC	Δ AUC vs 全局常数	配对 95% CI	Log loss	判读
预测时已有作答	3-5	10107 (6821/3286)	0.734	0.234	[0.218, 0.252]	0.546	区间高于 0
预测时已有作答	6-9	7877 (5336/2541)	0.730	0.230	[0.212, 0.248]	0.548	区间高于 0
折内知识点训练覆盖	1-39	28 (13/15)	0.600	0.100	[0.000, 0.183]	0.739	证据不足: 区间跨 0
折内知识点训练覆盖	200+	51024 (33380/17644)	0.714	0.214	[0.202, 0.225]	0.576	区间高于 0
折内知识点训练覆盖	40-199	377 (208/169)	0.761	0.261	[0.130, 0.335]	0.584	区间高于 0

更完整的六种方法指标（AUC、相对全局/概念常数 Δ AUC、Log loss、Brier、ECE、正负样本、概念与训练学生覆盖）见`public-bkt-strata.csv`。学生配对 bootstrap 区间针对收缩 BKT 与常数基线；其余方法只列分层点估计。区间跨零的层标为证据不足；1-39 次训练覆盖层只有 28 个测试作答，需要谨慎解释。

BKT 优化实验

开发集 184,631 次 OOF 预测、3,202 名学生。原始 BKT AUC=0.6741、Log loss=0.6476；概念 EM Log loss=0.5681。嵌套选型后单调逻辑校准模型 AUC=0.7214、Log loss=0.5659、Brier=0.1913、ECE=0.0060。相对概念 EM 的 Log loss 降低 0.0022，学生聚类配对 95% CI [0.0017, 0.0027]；ECE 区间跨零。

题目难度研究变体（稀疏题目回退概念参数）AUC=0.7324、Log loss=0.5593、Brier=0.1885、ECE=0.0091。相对概念 EM，AUC 增加 0.0154 (95% CI [0.0143, 0.0167])，Log loss 降低 0.0088 (95% CI [0.0082, 0.0094])；ECE 恶化点估计为 0.0031，其区间跨零。此实现是本项目研究适配器，不宣称等同于完整 KT-IDEM 或 pyBKT multigs 复现。

题目 EM 上限 100 轮、最大参数变化 $<1e-5$ 连续三轮收敛；5 个外层折均在 13-19 轮内收敛。嵌套选择主要落在收缩强度 50、逐机会遗忘 0.01 附近。参数边界用于提示失配或数据不足，不作为代码错误的直接证据。

历史测试集本轮回运行包含 51,429 次作答和 801 名学生；由于它此前已查看，不用于声明新验证或模型选型。

全文教材与120题新批次

当前批次 m3-fulltext-rag-20261004-v4，状态 completed。全文 OCR 为 347/347 页；新批次正式矩阵已完成，有效 / 观察 / 计划格为 480/480/480。AI 标注已保存检索 13710 条、引用 1595 条、可答性 120 题。真实人员复核待实际评审提交。旧 40 题保留会话历史，新开发和封存各 40 题采用单轮冷启动；BKT 训练结果沿用原版本。

教材以 2 倍缩放强制 RapidOCR，按不超过 50 页分成七批，347 页无遗漏、重复或乱序。已保存逐页原始 / 校正文本、行框、置信度、图像哈希及 AI 复核记录。重点补核覆盖 347 页，补充校正 4 页；印刷页码逐页确认 319 页，其余为空。重点核对不等于全部字符、二维图连接或人员复核认证。

仍有明确未确认重点内容的 PDF 页：79, 101, 102, 147, 200, 214, 220, 313。这类内容保留原始图像和具体原因，不补造图中关系。旧 OCR 及索引保留，独立新索引按 800 字分块、120 字重叠得到 629 片段，其中 575 个属于 313 个可作为可靠证据的正文页。

语义复核阶段另在 PDF 34、40、171、180 页发现代码字符 OCR 错误，并放大核对原页图形成独立 AI 勘误。勘误不回写已冻结的实验文本或索引；本轮结果仍使用上述固定版本，其算法文字与代码字符准确性须分别判断。未宣称教材程序整体可编译，人员复核仍待提交。

检索固定采用字符哈希向量与 BM25，两路各取 50，RRF 常数 60，最终证据 5 条；沿用证据不足判断，未接入 BGE 在线检索。检索关 / 约束开按规则零生成。

生成配置：deepseek-flash，温度 0.3，thinking.type=disabled，8192 tokens，自动重试 0；每格最多一次生成，未使用种子重复或推断性置信区间。AI 评估请求温度为 0。预算由本批次冻结授权读取：本轮 369/399 次，累计 857/887 次，未决 0 次。分阶段实际请求：预检 4 / 正式 331 / AI 标注 34，上限分别为 4 / 360 / 35；失败和未决计入账本。

每格发送前检查冻结配置、代码、教材、索引、题集、BKT 参数及预算。配置 SHA-256
4ac6128abca8473ba7111a2e44575f8d209182e3dcdaeb83e426bc3693b1480c；教材校正版 SHA-256
21d8ca58901be9b68eeddba793d505fe19309e6b8b260c9969568090cd9166b3；索引内容 SHA-256
549119cf5efae4deb29e565de3b76a6d0435393ee9b14ead80a85d53ae039c17；提示模板指纹

c078711439c16f3f4318430d2f1df4039ab405457c20bfaefa5fcc19442fdb35。原始prompt、模板源码及实际消息均独立归档，不写入正文或附录；参考答案、标签和标注理由仅进入评估。

停止原因：无；清理状态：gateway_tree_and_port_verified_closed。之前的停止批次及旧指纹不匹配批次保留原状态，仅作历史诊断，不进入当前正式比较。

本批次曾因独立引用诊断文件占用账本保留文件名而安全暂停；更名后核清未决请求并验证服务清理，沿原冻结批次断点续跑。已完成格逐项核对哈希不变，未重发；报告工具等非运行文件的工作区指纹变化单独记为历史，冻结运行文件仍严格逐项比对。

分区消融结果

合并三个分区的描述性结果：检索开启时，证据不足题进入生成由约束关闭的23/23 (100.0%)降为约束开启的15/23 (65.2%)；可答题未生成均为7/97 (7.2%)。证据约束仍允许部分证据不足题生成，尚不能当作可靠拒答保障。检索关 / 约束开的零生成来自固定规则，可答题也全部未生成，不构成性能提升证据。分区结果和动作口径见下表；这里评价进入生成的决策，不评价答案正确率。

条件	分区	有效 / 观察 / 计划	请求	不足时生成	可答时未生成	旧题动作匹配
检索开 / 约束开	旧40题	40/40/40	28	1/6 (16.7%)	7/34 (20.6%)	32/40 (80.0%)
检索开 / 约束开	新开发40题	40/40/40	38	6/8 (75.0%)	0/32 (0.0%)	不适用
检索开 / 约束开	封存40题	40/40/40	39	8/9 (88.9%)	0/31 (0.0%)	不适用
检索开 / 约束关	旧40题	40/40/40	33	6/6 (100.0%)	7/34 (20.6%)	32/40 (80.0%)
检索开 / 约束关	新开发40题	40/40/40	40	8/8 (100.0%)	0/32 (0.0%)	不适用
检索开 / 约束关	封存40题	40/40/40	40	9/9 (100.0%)	0/31 (0.0%)	不适用
检索关 / 约束开	旧40题	40/40/40	0	0/6 (0.0%)	34/34 (100.0%)	5/40 (12.5%)
检索关 / 约束开	新开发40题	40/40/40	0	0/8 (0.0%)	32/32 (100.0%)	不适用
检索关 / 约束开	封存40题	40/40/40	0	0/9 (0.0%)	31/31 (100.0%)	不适用
检索关 / 约束关	旧40题	40/40/40	33	6/6 (100.0%)	7/34 (20.6%)	32/40 (80.0%)
检索关 / 约束关	新开发40题	40/40/40	40	8/8 (100.0%)	0/32 (0.0%)	不适用
检索关 / 约束关	封存40题	40/40/40	40	9/9 (100.0%)	0/31 (0.0%)	不适用




图1 | 新批次矩阵覆盖与有效格

错误接受以证据不足题进入生成为分子，错误拒答以可答题未进入生成为分子；两者以已完成AI可答性判断的对应题数为分母，不等于答案正确率。缺失标签和无分母指标为N/A。动作匹配只用于原有预期动作的旧40题。停止批次不产生正式比较分数。




图2 | 四条件分区生成决策错误率

图2显示全部四条件、三个40题分区，行末依次列出证据不足题生成的分子 / 分母和可答题未生成的分子 / 分母。检索关 / 约束开按固定规则零生成，因此其不足时生成率为0、可答时未生成率为100%；这项取舍来自规则，不能作为拒答能力提升。所有比例均使用AI可答性标签，无种子重复或推断性置信区间。




图3 | 同题开启证据约束后的生成决策变化

图3以同一题从约束关闭到约束开启的决策作配对，分别在检索开、关时保留120题，共240个配对；按分区和AI可答性分层。检索开启时，证据不足题中5道旧题、2道开发题、1道封存题停止生成，另15道仍生成；97道可答题的决策均未改变，其中90道两条件都生成、7道两条件都未生成。检索关闭时，约束开启的规则使23道不足题和90道原本生成的可答题均停止生成，另7道可答题两条件都未生成。上述是有限构造题集的一次运行决策变化，不评价答案正确率或因果性性能增益；逐格哈希和配对计数已另存来源数据。

AI标注与检索质量

保存AI语义标注：检索13710条，引用1595条，可答性120题。原人员评审表独立保留。候选按问题与证据去重判断，再映射到方法排名；记录具体理由、证据位置、来源、版本和请求哈希。本地Codex结构审查的哈希明确记为本地复核凭据，不冒充供应商请求。AI标签仅用于探索性指标，未生成双人一致率或人员κ。

首次检索标注响应虽正常结束，但把问题编号和PDF页码混入标签字段，未通过语义标注格式校验，整次响应不进入指标且仍计入请求账本。随后独立冻结评估器版本 fulltext-ai-review-20261004-v4-evaluator2，每次528项，使用明确命名的输入字段和逐项来源行号校验；不更改已完成正式生成的冻结配置。评估器源码、输入和规则指纹及实际请求单独归档。最终检索标注协议异常9项；异常保留为无法判定，不补造标签。

格式通过不代表语义正确。另以Codex逐条读源核对17条历史候选，修正8条：包括把否定错误复杂度的直接证据误记为不相关，以及将仅覆盖算法步骤而缺少适用条件的片段记为直接覆盖。该抽查按已读正例、部分支持和负例对照选取，不是随机样本，不能据此估计总体误标率。供应商原标签表和本地复核凭据均独立保留。其余AI判断尚无真实人员复核，检索及题目评估与生成使用同一模型也可能存在共同偏差，引用另由Codex独立评估，指标仅作探索性比较。

15道原定义包含三轮的旧题，按正式实验实际发送的首轮另做Codex语义复核，并逐段核对教材行号和必要条件；原多轮判断独立保留。最终120题可答性表与实际首轮输入逐项匹配，复核没有增加供应商请求。

26题的供应商证据范围超过每段8行约束，但页码与起止行均在来源内；将原范围拆为每段至多8行，逐字核验后恢复供应商原可答性判断。未增加请求、未推断新语义标签，原响应及规范化凭据分别保留；来源越界范围不按此规则恢复。

候选池	分区	方法	计分题数	条件Recall@20	nDCG@5	无法判定条数
旧索引	旧40题	hash_dense	8	0.5625	0.2778	0
旧索引	旧40题	bm25	8	0.6250	0.2684	0
旧索引	旧40题	rrf	8	0.6250	0.2800	0
全文索引	旧40题	hash_dense	18	0.7963	0.4675	2
全文索引	旧40题	bm25	18	0.9167	0.6921	2
全文索引	旧40题	rrf	18	0.9259	0.6438	2
全文索引	新开发40题	hash_dense	24	0.8174	0.4296	3
全文索引	新开发40题	bm25	24	0.9542	0.7367	3
全文索引	新开发40题	rrf	24	0.9396	0.7438	3
全文索引	封存40题	hash_dense	17	0.7941	0.4477	4
全文索引	封存40题	bm25	17	0.8137	0.5301	4
全文索引	封存40题	rrf	17	0.9706	0.5612	4

Full-text retrieval quality

Exploratory estimates from completed AI judgments




图4 | 已标注候选池中的检索质量

Recall@20以每题已标注候选池中等级1或2的片段为分母，不是全教材召回。全文候选池来自两路Top-50并集；含无法判定条目的题目单独记录覆盖，不进入完整候选池指标。候选池全为等级0时相关分母为0，该题同样不进入均值；各方法在同一候选池中共用计分题集，旧索引与全文索引的计分题集可能不同，不能将跨索引均值差当作配对增益。

引用与答案证据覆盖

234个主张—来源配对由本地Codex逐条阅读64段实际引用原文，完成单条支持、211条不同主张的联合支持及来源定位评估，新增外部接口请求0次。配对单条标签为完整支持175、部分支持44、无支持10、矛盾1、无法判定4。另1359条无显式引用主张按引用结构记录无支持，2条未提取到主张的引用保留无法判定，总计1595条独立AI标注。此前DeepSeek引用请求HTTP 402作为失败历史保留，未重试；本地评估是用户明确授权的独立标注方式。原文、逐条理由、联合引用清单与哈希凭证单独归档，真实人员复核仍待提交。

来源 / 条件	分区	配对	单条完整支持	主张联合覆盖	来源定位	无法判定
旧引用	旧40题	119	94/119 (79.0%)	97/261 (37.2%)	119/119 (100.0%)	0
检索开 / 约束开	旧40题	21	15/21 (71.4%)	16/100 (16.0%)	21/21 (100.0%)	0
检索开 / 约束开	新开发40题	32	20/32 (62.5%)	23/149 (15.4%)	32/32 (100.0%)	0
检索开 / 约束开	封存40题	28	22/28 (78.6%)	22/74 (29.7%)	28/28 (100.0%)	1
检索开 / 约束关	旧40题	19	17/19 (89.5%)	17/188 (9.0%)	19/19 (100.0%)	1
检索开 / 约束关	新开发40题	5	2/5 (40.0%)	2/220 (0.9%)	5/5 (100.0%)	0
检索开 / 约束关	封存40题	10	5/10 (50.0%)	5/117 (4.3%)	10/10 (100.0%)	2
检索关 / 约束关	旧40题	0	N/A	0/165 (0.0%)	N/A	0
检索关 / 约束关	新开发40题	0	N/A	0/187 (0.0%)	N/A	0
检索关 / 约束关	封存40题	0	N/A	0/109 (0.0%)	N/A	0

全文批次合并分区：检索开 / 约束开单条完整支持为57/81 (70.4%)，主张联合证据覆盖为61/323 (18.9%)；检索开 / 约束关分别为24/34 (70.6%)和24/525 (4.6%)。所有已配对来源均可定位，但定位正确不保证语义支持，且大量主张没有显式引用。两个条件提取的主张与引用分母不同，这些为描述性份额，不作为同一主张的配对因果效应或答案正确率。




图5 | 引用支持与主张证据覆盖

单条支持、实际引用的联合支持与来源定位分别判断，使用完整支持 / 部分支持 / 无支持 / 矛盾 / 无法判定五分类。只计回答实际引用；无显式引用主张记为引用支持缺失，不据此判断事实错误。未被回答引用的全文内容不能补充支持率。无法判定保留在引用审计分母并单列数量，完整支持比例表示已确认的支持份额，不把未知标签判成事实错误。

原版本引用审计

原版本审计口径：旧120格

指标	结果	含义
字段可解析率	540/540 (100.0%)	定位字段
来源实际可定位率	92/92 (100.0%)	回答可见引用
语义完整支持率	82/119 (68.9%)	主张—引用配对
事实主张证据覆盖率	86/261 (33.0%)	需证据事实主张

AI 辅助审计将 119 个主张—回答实际引用配对标为完整支持 82、部分支持 22、无支持 15；261 个事实性主张中 86 个完整获得证据支持、13 个部分支持、162 个无支持，156 个事实主张没有回答可见引用。检索候选、决策附带引用和回答实际引用分开保存；只有最后一类进入主张—引用语义分母。未生成、无主张、无引用及孤立引用分开记录。

两份旧人工盲评仍未返回。当前所有语义判断都是未校准 AI 辅助结果；本报告借鉴 ARES 的上下文相关性/忠实度/答案相关性维度，没有声称完成人工校准。次级旧汇总与源表冲突（67 对/252 主张 vs 主源表 119 对/261 主张），按源级明细保留 119/261 主口径，并另存差异核对。

旧课程索引的离线耗时

课程检索阶段	中位数 ms/题	P95 ms/题
hash_dense_ms	91.2	96.4
bm25_ms	112.9	115.8
hash_rrf_ms	0.1	0.2
bge_dense_query_ms	201.9	228.4
bge_rrf_merge_ms	0.1	0.2
bge_reranker_50_ms	14247.6	15251.6

该旧BGE检索的人员盲评质量为N/A；全文检索AI指标见前文。排序分数不作为Recall或回答质量。

NoMIRACL 中文完整固定候选评测

已完成全部3,770题：开发集1,475题（相关393、非相关1082），测试集2,295题（相关920、非相关1375）。评分覆盖31,826 个不同文档、37,599个配对，保存150,396条四方法排名记录。

数据revision ecd08778d0426a5ca28ac99763b0c9ddc2c78e68。按固定版本的官方加载逻辑过滤语料不存在的95条qrel，其中35条正例（开发32条 / 13正例；测试63条 / 22正例）。不排除任何题目，不补造缺失文本；语料中5,773条内容完全相同的重复行合并，冲突ID拒绝运行。

固定候选内比较BGE-M3 dense、BM25、两路RRF-60和BGE reranker v2-m3；BM25 k1=1.2、b=0.75，沿用中文二字切分与小写字母数字分词。文本为标题加正文，文档与配对最多512 tokens，查询256 tokens；分数并列按docid升序。此处RRF使用每题完整固定候选的两路排名，与教材在线Top-50检索范围不同。

专用本地环境FP32、关闭TF32，编码批大小2，重排4；实际阶段设备：documents=cuda, queries=cuda, reranker=cuda。每256项原子保存，输入、模型、代码、评分配置和设备指纹绑定缓存；CUDA阶段失败时完整改用CPU FP32、16线程，隔离设备缓存。有限输出检查和数量校验通过，新增外部模型请求0次，累计账本857/887保持不变。

固定候选排序

方法	dev相关题平均 nDCG@5 (n=393)	test相关题平均 nDCG@5 (n=920)
BGE-M3 dense	0.7508	0.7618
BM25	0.4248	0.4296
BGE-M3 + BM25 RRF-60	0.6402	0.6563
BGE reranker v2-m3	0.7863	0.7969

NoMIRACL Chinese: fixed-candidate ranking

All 3,770 queries and 37,599 available candidate pairs scored




图6 | NoMIRACL 中文固定候选排序

nDCG@5在保留的候选与qrel内计算，只对相关题取均值。没有全库Recall，没有生成答案评测；本轮单次固定快照不报告重复实验置信区间。

两个分区重排平均nDCG@5均最高；测试集0.7969，高于BGE-M3 dense的0.7618。两路RRF为0.6563，低于稠密单路，说明本固定候选与分词配置下，融合不保证排序收益。这里只比较本快照，不据此推广到全库或其他配置。

冻结门限的测试集结果

仅用开发集最大重排分数选门限 $\theta=6.42378902$ ，接受规则为最大分数 $\geq \theta$ 。在非相关题 $FAR \leq 5\%$ 条件下最大化相关题接受率，并列选较低门限。开发 $FAR=4.99\%$ ，相关题接受率=29.01%。门限在测试指标计算前独立冻结；测试标签未用于选型或调参。

测试指标	分子 / 分母或AUC比较单位	结果
错误接受 FAR	62/1375	4.51%
错误拒绝 FRR	645/920	70.11%
最大重排分数 AUC	920相关 × 1375非相关	0.8007




图7 | NoMIRACL 测试集证据门限错误率

FAR以非相关题接受数为分子、1,375题为分母；FRR以相关题拒绝数为分子、920题为分母。AUC使用最大重排分数和题级相关标签，分数并列取平均秩。这些是固定候选排序及门限指标，不能当作教材实验的回答正确率或全库召回能力。预训练模型与公开基准的潜在数据重叠仍是解释限制。

开发集5%错误接受上限对应的门限在测试集拒绝了645/920道相关题（70.11%）。因此较低FAR伴随较高FRR，不能仅凭错误接受率宣称门限可靠或适合课程直接部署。未利用测试结果调整门限。

耗时与冻结证据

阶段	耗时	单位
文档编码	589.94	秒 / 完整阶段
查询编码	25.15	秒 / 完整阶段
四方法排序与指标	2.41	秒 / 完整阶段
配对重排	648.90	秒 / 完整阶段
本次运行总墙钟	1338.70	秒 / 含加载与编排
重排平均每配对	17.259	毫秒 / 配对；不是中位数

评分配置SHA-256 dcedb895a8ea629bacb94b48903db5a344d34d7eb96094649179ef5cf54fd0f9；门限文件SHA-256 c73a29199a924ae4fd1b39fc1fc46ffed2acc43d34faff1b98107c045fc024a2。总墙钟包含加载、数值预检及编排，阶段计时来自保存批次；平均每配对明确以毫秒给出，不冒充P95或中位数。完整逐题数据和四方法分数排名见`nomiracl-zh-per-query.csv`及`nomiracl-zh-candidate-ranks.csv`。配置、缓存、日志、清理证明和归档哈希由交付清单追踪。

模型	固定 revision	许可	权重文件 SHA-256
BAAI/bge-m3	5617a9f61b028005a4858fdac845db406aefb181	mit	2,271,145,830 bytes; SHA-256 b5e0ce3470abf5ef3831aa1bd5553b486803e83251590ab7ff35a117cf6aad38

模型	固定 revision	许可	权重文件 SHA-256
BAAl/bge-reranker-v2-m3	953dc6f6f85a1b2dbfca4c34a2796e7dde08d41e	apache-2.0	2,271,071,852 bytes; SHA-256 d9e3e081faff1eefb84019509b2f5558fd74c1a05a2c7db22f74174fce db5286

人工标注包与复核流程

私有标注包状态: ready_for_human_review; all new question gold labels pending。包含 119 个引用配对、3920 个检索标注行（旧候选池 3141 对，新增课程检索去重候选 779 对）、开发/封存各 40 题、两份独立盲评 CSV/XLSX、裁决表、codebook 与导入校验器。所有人工字段保持空白。

指导流程：先各自完成 20 个引用配对和 30 个检索候选试标；确认规则后分批独立标注；引用使用五分类 Cohen’s κ ，检索 0/1/2 使用二次加权 κ ；报告缺失、原始一致率、 κ 、分歧理由，再由第三人裁决。未收到的人工作业不估填分数。

评审文件仅保存在项目授权的本地私有目录；报告、CSV 指标和图表不携带学生回答、教材原文摘录或模型权重。

复现文件与图表

当前图表均由 R 4.6.1 生成，提供 SVG、PDF、600-dpi PNG、R 源码和来源数据。历史占位图及停止证据已独立归档；不纳入当前比较。

数据覆盖与证据状态

数量对应不同单位，按清单逐项标示；颜色表示证据或访问状态。




图8 | 数据覆盖与证据状态

BKT 分层 AUC 差异

相对训练折全局常数; * 表示收缩 BKT 的配对区间跨零。历史测试仅作回归诊断。





图9 | BKT 分层相对常数基线的 AUC 差异

嵌套开发 OOF 指标

校准与区分能力共同报告；ECE 越低越好。



题目难度 EM 收敛

100 轮上限；5 个外层折均收敛。




图10 | 嵌套 OOF 校准指标与 EM 收敛

引用指标拆分

分母各不相同：字段格式、可定位引用、主张—引用配对、事实性主张。AI 辅助判定，未人工校准。




图11 | 旧版本引用指标分母与审计来源（历史诊断）

验收与复现检查

检查项	状态	结果
targeted_pytest	passed	85 local tests passed; session/graph/runtime/provider controls, pre-HTTP terminal failures, cleanup persistence, OCR recovery, partition isolation, budgets, ranked-pool metrics and AI provenance.
python_syntax	passed	30 current experiment, annotation, report and delivery modules compiled in memory.
r_figure_generation	passed	R 4.6.1 exported 11 active SVG/PDF/600-dpi PNG charts. Historical placeholders archived; current fulltext charts retained.
figure_visual_qa	passed	Five current figures inspected, including decision rates from 480 cells and 240 matched constraint transitions; independent PDF line geometry and rendered glyph sizes pass. Original Cairo audit findings retained with the geometry correction.
report_pdf	passed_all_pages	All final pages rendered and visually reviewed. Dynamic page count and exact PDF/image hashes are recorded in render-manifest.json and verified by delivery validation.
annotation_import_validation	passed_ai_only	Prepared 276 citations (119 pairs), 3920 old and 9790 new candidates, 120 questions. Saved semantic rows: retrieval 13710, citations 1595, questions 120. Personnel fields remain untouched; no personnel kappa.
rag_formal_ablation	completed	Batch m3-fulltext-rag-20261004-v4; eligible/observed/planned 480/480/480. Phase attempts: {'preflight': 4, 'formal': 331, 'annotation': 34}. Cumulative 857/887; unresolved 0; gateway_tree_and_port_verified_closed.
kdd_algebra_full_master_data	pending_access	Official complete _master.txt files were not obtained; no truncated data substituted.
nomiracl_full_fixed_candidate_evaluation	completed	9 local tests; 3770 queries, 37599 fully scored pairs, 150396 ranking rows; all finite. Dev-only threshold and test nDCG/FAR/FRR/AUC independently recalculated; zero external requests.
nomiracl_and_coverage_figure_qa	passed	Two NoMIRACL charts and updated coverage chart inspected. Every final PDF passes independent line-box collision and rendered glyph audits; source data, units and denominators verified.

pytest 的独立临时文件根使用实验目录中的 workspace-local fixture；宿主机 OS 临时目录的枚举权限受限。定向测试通过后保留其测试专用临时目录，未覆盖用户数据。

研究方法依据

方法/数据	本实验中的用法与边界	来源
pyBKT / BKT+Forget / KT-IDEM	BKT 参数估计、遗忘和题目难度模型的候选方法；本轮题目研究适配器不等于完整复现。	pyBKT, 2021
边界参数解释	参数落边界作为失配/数据稀疏诊断线索，不直接视为实现缺陷。	Doroudi & Brunskill, EDM 2017
BGE-M3	多语种 1024 维稠密向量；与 BM25 做独立模型索引比较。	BGE-M3 paper, model card
RRF / reranker	常数 60 融合两路 Top-50；BGE reranker v2-m3 重排融合候选。分数不沿用旧余弦阈值。	RRF, SIGIR 2009, reranker card
NoMIRACL / MIRACL	固定候选证据门限辅助验证不等同于全库召回；预训练数据潜在重叠作为限制。	NoMIRACL, MIRACL
ARES 评估维度	用于设计引用审计标签与维度；没有人工校准，不宣称 ARES 评分。	ARES, NAACL 2024
KDD Cup Algebra I	计划中的真实数学/步骤级新验证数据；本轮完整 _master.txt 待官方访问。	KDD Cup 2010 official data

未完成项与验收边界

工作项	状态	完成条件
课程检索相关性/回答性	AI检索13710条 / 题目120题；人员待复核	AI探索性分组指标已计算；真实人员提交后核验标签并另行计算人员一致率
Algebra I KDD 新验证	等待官方完整数据访问	登记 _master.txt 文件、许可、SHA-256、流失与按学生 80/20 固定分割
MIRACL 中文全库召回	未运行	规模化索引/资源可用后做 corpus-wide Recall；不以 NoMIRACL 替代
结构分块与证据预算消融	未运行	在选定检索器上单独比较结构切块与 1024/2048/4096 tokenizer token 预算

证据文件与哈希

- ASSISTments 源数据 SHA-256: 162ef8d2d28bcbfea6591a282994062bd8d5eaa00636544292a0d268dca6e5da。
- 构造集 SHA-256: b833e457533e1e517a89d017ac42f7a27351bc44f0e6162aae82b32da130abc6。
- 原 RAG 冻结教材索引 SHA-256: 4712bd0cec0e3a687b815d4b8c935236cc49a6c153ee8fc2068835474fab9bfff。
- 100 轮嵌套 OOF 文件 SHA-256: 84f649dbec666692d590b8fb7334c1b45ecd4d6c8a2eca6c5ababf779b2ae14b。
- 配对区间文件 SHA-256: dddabc5664b44602a4eae38d73ba17142ca9bd21bfed11e424ba25ee7115f0c4。
- 引用汇总差异状态: conflicting_legacy_summary_preserved_but_not_combined；主源表配对数 119。
- 公开数据表、生成脚本、环境锁和图表文件 SHA-256 由 `figure-data-manifest.json` 逐项登记。
- 本报告 PDF/Markdown、核心私有证据包清单、原始批次关联及全部交付文件哈希汇总在 `delivery-manifest.json`。